

Ames 房价预测

从基线筛选到稳健四模型融合

围绕数据语义、交叉验证、模型互补性和误差边界完成的一次端到端回归实践。

Kaggle Public	排名快照	排名百分比	稳健本地 RMSE
0.12163	430 / 3,454	Top 12.45%	0.10483

最终结论 V3 比 V2 的公开分数改善 0.00042，排名快照由 493 升至 430。结果可复现，但本地验证仍明显偏乐观，价格两端仍是主要误差来源。

结果快照：2026-08-24 | Kaggle team: kimzaiyi1

执行摘要

本项目使用 Ames Housing 数据预测住宅成交价格。最终方案由 Elastic Net、Gradient Boosting、XGBoost 和 RBF-SVR 组成，通过重复 OOF 预测、目标分层的元交叉验证和轻度线性校准生成提交结果。

答案先行 V3 Public Score 为 0.12163，排名快照为 430 / 3,454 (Top 12.45%)。相较 V2 有真实但有限的提升。本地 0.10483 没有完全兑现到榜单，因此报告把验证偏差和尾部误差作为核心结论。

- 有效做法：结构性缺失值处理、对数目标、OOF 选型、模型互补性检查。
- V3 改进：加入 RBF-SVR、使用目标分层元交叉验证、限制校准幅度。
- 主要局限：样本量小、重复实验造成选择偏差、价格两端仍回归均值。
- 可信边界：未使用外部成交价或公开泄漏标签，不承诺隐藏测试集达到 0.06。




图 1 Kaggle 公开分数与排名快照

1. 问题定义与数据

训练集包含 1,460 套房屋、81 列；测试集包含 1,459 套房屋、80 列。除 Id 外共有 79 个预测变量，覆盖面积、年份、质量等级、社区和房屋类型。目标变量 SalePrice 只出现在训练集。

数据项	训练集	测试集	处理判断
行数	1,460	1,459	训练时移除 2 个明确面积异常样本
预测变量	79	79	Id 不作为特征
目标	SalePrice	隐藏	预测 $\log(\text{SalePrice})$, 提交前还原
主要缺失	PoolQC、Alley、Fence 等	同类	区分无设施与未知

比赛评价接近对数价格上的均方根误差。直接预测 $\log(\text{SalePrice})$ 可以减弱少数高价房对平方误差的支配，并让误差更接近相对偏差。




图 2 原始房价右偏，对数变换后更接近对称分布

2. 数据预处理判断

2.1 缺失值不是一个问题

PoolQC、GarageType、BsmtQual 等字段中的空值经常表示房屋没有对应设施。本项目把这类值编码为 None；只有设施存在但描述字段仍为空时才标记 Missing。剩余数值缺失在每个训练折内部按中位数填充，并增加缺失指示变量。

LotFrontage 与社区布局相关，因此 SVR 分支按训练折的 Neighborhood 中位数补充，无法匹配时再使用全局中位数。验证折没有参与统计量计算。




图 3 缺失最多的字段及其业务语义

2.2 异常值处理保持克制

Id 524 和 1299 的居住面积超过 4,000 平方英尺，但成交价明显偏低，符合预先设定的面积异常规则，仅在模型训练阶段移除。其余高价和大面积样本保留，避免为了降低本地误差而删除真正困难的房屋。

2.3 特征工程

- 规模：总使用面积、总浴室数、总门廊面积、总室外面积。
- 时间：售出时房龄、翻新后年限、车库年龄。

- 设施：车库、地下室、壁炉、泳池、二层和砖石存在标记。
- 关系：质量×居住面积、质量×总面积、车库容量×车库面积。
- 顺序：质量、地下室采光、车库完成度等类别映射为等级分数。

3. 模型筛选与取舍

初始候选覆盖十类模型。所有比较使用 OOF RMSE，训练拟合误差不参与选型。最佳单模是 Lasso/Elastic Net，Gradient Boosting 和 XGBoost 单模略弱但残差互补。随机森林、Extra Trees 和早期 SVR 版本落后，因此没有为增加模型数量而保留。

基线模型	OOF RMSE	折间标准差
Lasso	0.11000	0.00746
ElasticNet	0.11024	0.00747
Ridge	0.11219	0.00846
GradientBoosting	0.11389	0.01104
CatBoost	0.11558	0.00704
XGBoost	0.11613	0.00668
LightGBM	0.12128	0.00798




图 4 十类基线模型的五折 OOF 比较




图 5 从最佳单模到 V3 稳健融合的验证改进

独立判断 V3 没有继续增加树模型。V2 的树模型残差相关系数超过 0.92，再堆同类模型通常只会让本地分数更好看。重新调参后的 RBF-SVR 虽不是最强单模，但与 XGBoost 的残差相关性约为 0.853，提供了更有价值的差异。

4. 最终四模型，用大白话解释

模型	直观理解	主要贡献	主要局限
Elastic Net	给各项条件估算稳定的加减价	稀疏高维、整体线性关系	难表达复杂门槛
Gradient Boosting	后一棵树专门修正前一轮错误	非线性、异常值稳健	与其他树模型易同质
XGBoost	带复杂度约束的高效提升树	交互、稀疏特征	参数多、可能过拟合
RBF-SVR	让特征相似的房屋得到相近估价	平滑非线性边界	对缩放和参数敏感

融合不是让四个模型投票选冠军，而是把它们 OOF 预测作为新的证据。每套训练房屋都由没有见过它的模型预测，再根据这些预测估计组合权重。

5. 权重与校准

模型	最终权重	权重含义
Elastic Net	25.9%	稳定线性基准
Gradient Boosting	23.4%	稳健非线性纠错
XGBoost	24.3%	复杂交互与分裂
RBF-SVR	26.5%	平滑核方法补充

权重要求非负、总和为 1，并加入 0.01 的 L2 惩罚，防止某个随机折把权重推向单一模型。8 组目标分层元交叉验证用于评估权重稳定性，最终使用 40 组折内权重的平均值。

融合后校准斜率为 1.0157，仅把预测范围拉开约 1.6%。斜率被限制在 0.98 至 1.04，避免根据同一批残差做激进修正。




图 6 V3 四模型融合权重

6. 实证结果

版本	稳健本地 RMSE	Public Score	排名快照
V2	0.10587	0.12205	493 / 3,454
V3	0.10483	0.12163	430 / 3,454

V3 预测中位数约 156,841 美元，最小值约 46,061 美元，最大值约 847,620 美元。提交文件共有 1,459 行，列名严格为 Id 和 SalePrice，Id 顺序与官方样例一致，没有缺失、重复或非正价格。




图 7 训练价格与测试预测价格分布

7. 误差诊断

7.1 价格两端仍然最难

最低价格十分位的 OOF RMSE 为 0.19518，平均残差为 -0.07525；最高价格十分位的 OOF RMSE 为 0.10717，平均残差为 0.03708。负残差表示低价房仍被高估，正残差表示高价房仍被低估。




图 8 按实际价格十分位分组的 OOF 误差与偏差




图 9 OOF 预测与实际对数价格

7.2 本地验证仍偏乐观

V3 本地稳健 RMSE 为 0.10483，Public Score 为 0.12163，差距为 0.01680。对抗验证平均 AUC 约 0.516，接近随机判断，因此没有证据支持强烈的整体训练/测试分布漂移。

- 训练样本不足 1,500 个，价格两端样本更少。
- 多轮特征和参数实验反复使用同一训练集，产生模型选择偏差。
- 最终四个成员的残差仍然较高相关，真正的模型多样性有限。
- 权重和校准来自同一批 OOF 样本，不能替代完全独立的测试集。




图 10 稳健本地验证与 Kaggle Public Score 的差距

8. 为什么没有把 0.06 当作完成标准

边界说明 隐藏测试标签使任何具体 Kaggle 分数都无法在提交前保证。公开榜单中还存在外部标签、公开泄漏或直接重建测试答案的极低分提交，它们不能代表正常机器学习泛化能力。

为了让作品经得起复现和面试追问，本项目没有使用外部成交价，也没有逐行修改测试答案。0.12163 不是接近完美，但它是一条可以解释、可以复现、没有依赖测试标签的结果。

9. 质量检查与复现

检查项	结果	证据
提交结构	通过	1,459 行; Id、SalePrice 两列
数值有效性	通过	无 NaN/Inf, 价格全部大于 0
Id 一致性	通过	唯一、递增、与样例顺序一致
完整重训	PASS	最大 log 差 $3.14e-07$
图表	通过	10 张图均完成像素与尺寸检查
Notebook	通过	5 个代码单元全部执行, 无错误输出

完整重训与已提交 V3 的最大价格差约 0.15 美元, 最大对数差为 $3.14e-07$ 。该差异来自 XGBoost 多线程浮点计算, 不影响 Kaggle 五位小数分数。

10. 下一步改进

- 预留一块从未参与特征和参数选择的验证集, 或使用嵌套交叉验证。
- 针对低价和高价房设计分层模型或分位数辅助目标, 并放入外层验证检验。
- 使用重复目标分层折重训所有基础模型, 比较切分策略的公共榜单稳定性。
- 研究社区×房龄、质量×面积等分层交互, 同时控制高基数类别方差。
- 通过 bootstrap 给融合权重报告稳定区间, 而不只报告一个点估计。

结论

项目完成了从数据理解、可复现预处理、模型筛选、融合、误差诊断到 Kaggle 提交的闭环。V3 比 V2 有小幅真实提升, 排名快照进入前 12.45%。更重要的结论是: 后续最需要加强的并不是继续增加模型数量, 而是建立更独立的验证层、降低选择偏差, 并专门处理价格两端的系统性误差。

附录：文件与证据索引

内容	位置
最终训练入口	src/train_and_predict.py
数据处理与公共函数	src/house_prices_core.py
结果复核 Notebook	notebooks/final_results_walkthrough.ipynb
最终提交	results/submission_v3.csv
Kaggle 提交历史	results/kaggle_submission_history.csv
排名快照	results/kaggle_rank_snapshot.csv
完整重训检查	results/reproducibility_check.json

口径说明：分数越低越好；排名和参赛队数量为 2026-08-24 快照，后续可能变化。所有本地误差均在移除两条预定义面积异常样本后计算。